

# TD 3 — Régressions MCO (EViews)

## Régression linéaire : rappel & pratique

### Modèle de régression linéaire simple

Une régression consiste à expliquer les variations d'une variable dépendante  $Y$  par celles d'une ou plusieurs variables indépendantes  $X$ .

On suppose la relation (droite de régression) :

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i, \quad i = 1, \dots, N$$

où  $\varepsilon_i$  est centré et non corrélé aux régresseurs.

**Objectif MCO (OLS).** Estimer  $\beta_0, \beta_1$  en minimisant la somme des carrés :

$$\min \sum_{i=1}^N \varepsilon_i^2 = \min \sum_{i=1}^N (Y_i - \beta_0 - \beta_1 X_i)^2.$$

#### Tip

$\beta_1$  Représente ici la magnitude de “l’effet” de la variable  $X_1$  sur  $Y$ .  $\varepsilon_i$  Représente la partie non expliquée de la relation (ou terme d’erreur)

---

### Terme d'erreur

L'introduction du terme d'erreur recouvre deux grands types d'erreurs :

Erreur de spécification :

Les variables introduites ne sont pas suffisantes pour expliquer toutes les variations de  $Y$

Erreur de mesure :

La variable expliquée ( $Y$ ) est mesurée de manière imparfaite (bruitée)

---

## Prédiction de Y

Une fois estimée, la relation s'écrit:

$$Y_i = \hat{\beta}_0 + \hat{\beta}_1 X_i + \hat{\varepsilon}_i$$

Avec  $\hat{\varepsilon}_i$ , terme d'erreur estimé aussi appelé résidu, on peut prédire Y:

$$\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_i$$

---

## Graphique 1 — Nuage de points + droite OLS

```
set.seed(42)
N <- 60
x <- sort(runif(N, 0, 10))
y <- 2 + 0.8*x + rnorm(N, sd = 1.5)
df <- data.frame(x, y)
mod <- lm(y ~ x, data = df)

plot(df$x, df$y, pch = 19, xlab = "X", ylab = "Y", cex.lab = 1.4)
abline(mod, lwd = 3)

b0 <- coef(mod)[1]
b1 <- coef(mod)[2]

## ---- 0 : ordonnée à l'origine ----
points(0, b0, pch = 21, bg = "blue", cex = 1.8)
arrows(0.6, b0 + 0.7, 0.1, b0 + 0.1, length = 0.12,
       col = "blue", lwd = 3)
text(0.8, b0 + 1.1, expression(beta[0]),
     col = "blue", cex = 1.6, font = 2)

## ---- Triangle rectangle pour la pente ----
x0 <- 2 # point de départ en X
y0 <- b0 + b1*x0 # point sur la droite

# Base de 1 en X et hauteur correspondante en Y = b1
```

```

x1 <- x0 + 1
y1 <- b0 + b1*x1

# Triangle
segments(x0, y0, x1, y0, col="red", lwd=3) # base ( $\Delta x = 1$ )
segments(x1, y0, x1, y1, col="red", lwd=3) # hauteur ( $\Delta y = 1$ )
segments(x0, y0, x1, y1, col="red", lwd=3, lty=2) # hypoténuse

# Étiquettes
text((x0+x1)/2, y0 - 0.7, "1", col="red", cex=1.4, font=2) #  $\Delta x$ 
text(x1 + 0.4, (y0 + y1)/2,
     bquote(beta[1] == .(round(b1,2))),
     col="red", cex=1.4, font=2) #  $\Delta y = 1$ 

legend("topleft",
      legend = sprintf(" $\hat{Y} = \%.2f + \%.2f X$ ", b0, b1),
      bty = "n", cex = 1.2)

```




Figure 1: et illustrée par un triangle rectangle ( $\Delta x = 1$ ,  $\Delta y = 0.86$ ).

### Forme matricielle (régression multiple)

En multiple :  $Y = X\beta + \varepsilon$ ,  $\hat{\beta} = (X'X)^{-1}X'Y$ .

## Exemple avec deux régresseurs

```
set.seed(123)
N <- 120
x1 <- runif(N, 0, 10)
x2 <- rnorm(N, 5, 2)
y <- 1.5 + 0.6*x1 - 0.3*x2 + rnorm(N, sd = 1)
d <- data.frame(y, x1, x2)
m <- lm(y ~ x1 + x2, data = d)
summary(m)
```

Call:

```
lm(formula = y ~ x1 + x2, data = d)
```

Residuals:

Min	1Q	Median	3Q	Max
-1.78604	-0.62855	-0.05144	0.66068	2.06691

Coefficients:

	Estimate	Std. Error	t value	Pr(> t )
(Intercept)	1.87289	0.26031	7.195	6.43e-11 ***
x1	0.61541	0.03088	19.931	< 2e-16 ***
x2	-0.37545	0.04565	-8.224	3.07e-13 ***

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.9416 on 117 degrees of freedom

Multiple R-squared: 0.7792, Adjusted R-squared: 0.7755

F-statistic: 206.5 on 2 and 117 DF, p-value: < 2.2e-16

### Note

Ceci est un exemple de tableau de régression, sur Eviews, le tableau sera similaire, mais un peu différent, celui-là a été fait dans R pour l'exemple.

## Procédure sur EViews

### Estimation

- Faire Object → New Object → Equation
  - Autre méthode :
    - 1. Sélectionner les variables en débutant par la variable dépendante (Y)
    - 2. Faire Open → as Equation
  - La fenêtre ouverte a deux onglets :  
Specification : Entrer la spécification choisie  
Options :
    - Cet onglet sert pour la correction de la matrice de variance-covariance
    - Nous ignorons pour le moment cet onglet
- 

### Estimation

- Equation specification : Permet d'entrer l'équation estimée  
Il faut mettre d'abord la variable expliquée (Y) puis les variables explicatives (X1 ; X2, . . . ) : Y X1 X2 . . . c  
c sert à spécifier l'introduction d'une constante  
Nota : Si la deuxième méthode est utilisée, l'équation est déjà spécifiée mais peut être modifiée
  - Estimation Settings :  
Method : Permet de choisir l'estimateur (MCO [LS] par défaut)  
Sample : Permet de choisir l'échantillon retenu
-

## Commandes post-estimations

- Les coefficients estimés sont conservés dans l'objet `c`
  - Les résidus estimés de la dernière équation sont stockés dans "resid"
  - Name :
    - Permet de conserver la régression dans un workfile
  - View →representation :
    - Permet de visualiser la ligne de commande effectuée, l'équation théorique et l'équation avec les valeurs estimées des coefficients
  - View →estimation output :
    - Permet de visualiser les résultats bruts de la régression.
- 

## Commandes post-estimations

- View →actual, fitted, residual :
  - actual : valeur de la variable dépendante utilisée dans la régression,
  - fitted : valeurs de la variable dépendante prédites par la régression en appliquant les coefficients de la régression sur les variables explicatives,
  - residual (actual-fitted) : indication sur les erreurs de prévision éventuelles, bornes à 5%.
- Freeze :

Permet de conserver les résultats.

---

## Commandes post-estimations

- Il est possible de vouloir conserver plusieurs éléments de l'équation estimée
  - Ex : Pour calculer des points de retournement ou pour certains tests il faut conserver les  $R^2$ , la SCR, . . .
- Pour ce faire, il faut généralement de créer un objet (scalaire, matrice) qui puisse accueillir ces nouveaux éléments
  - Exemples :

- Scalaire : `scalar nom=nomequation.operation`
- Matrice : `matrix nom=nomequation.operation`
- Ex : `scalar rsq=eq1.@r2`
- Ex : `matrix coefficients=eq1.@coefs`

#### Tip

L'opération commence par `.@` en général

## Commandes post-estimations

Quelques éléments disponibles (non exhaustif):

Élément	Opération	Type d'objet
$R^2$	<code>@r2</code>	scalar
$R^2$ ajusté	<code>@rbar2</code>	scalar
SCR	<code>@ssr</code>	scalar
Coefficient pour la $i$ -ème variable	<code>c(i)</code>	scalar
t-stat pour la $i$ -ème variable	<code>@tstats(i)</code>	scalar
Matrice de variance-covariance	<code>@coefcov</code>	matrix
Matrice des coefficients	<code>@coefs</code>	matrix
Matrice des t-stat	<code>@tstats</code>	matrix

Une liste plus complète est disponible dans Users Guide II page 16

## Le coefficient de détermination : Le $R^2$

- Le pouvoir explicatif du modèle

L'économétrie cherche à expliquer les variations de  $Y$ . Ceci est la variabilité totale (SCT pour somme des carrés totale) et est donnée par :  $SCT = \sum_{i=1}^N (y_i - \bar{y})^2 = SCE + SCR$

Cette variabilité se décompose en :

- Variabilité expliquée : SCE (pour somme des carrés expliquée)

- Variabilité non expliquée : SCR (pour somme des carrés des résidus)

---

### Le coefficient de détermination : le $R^2$

- Le coefficient de détermination mesure le pouvoir explicatif du modèle et se calcule comme suit :

$$R^2 = \frac{SCE}{SCT} = 1 - \frac{SCR}{SCT} \quad \text{avec} \quad \begin{cases} SCR = \sum_{i=1}^N \hat{\varepsilon}_i^2 \\ SCT = \sum_{i=1}^N (y_i - \bar{y})^2 \end{cases}$$

- Ce coefficient mesure la qualité de l'ajustement de la régression en indiquant le pourcentage de la variance totale expliquée par le modèle :
  - Si (  $R^2 \rightarrow 1$  ) : le modèle est **très explicatif**.
  - Si (  $R^2 \rightarrow 0$  ) : le modèle est **peu explicatif**.

---

### Le coefficient de détermination : le $R^2$

- Il faut en réalité faire attention avec le (  $R^2$  ) :
  - Le (  $R^2$  ) augmente mécaniquement avec l'ajout de variables explicatives.
  - Il faut par conséquent privilégier une version ajustée du nombre de degrés de liberté, le (  $R^2$  ) ajusté :

$$\bar{R}^2 = 1 - (1 - R^2) \frac{N-1}{N-p}$$

- (  $N$  ) : nombre d'observations
  - (  $p$  ) : nombre de variables explicatives (sans la constante)
  - Le (  $R^2$  ) n'est pas un objectif en soi, il ne faut pas chercher à le maximiser.
-



# Significativité statistique

## La significativité simple

- **Objectif** : déterminer si le coefficient estimé est précis.
- Pour cela, on fait un **test de Student** à partir de :
  - la valeur estimée du coefficient (  $\hat{\beta}_j$  ),
  - et la valeur estimée de son écart-type (  $\hat{\sigma}_\beta$  ).

*Rappel : l'écart-type mesure la dispersion d'une série autour de sa moyenne.*

- La statistique de test est la suivante :

$$t_{\beta_j} = \frac{\hat{\beta}_j - \beta_{th}}{\hat{\sigma}_\beta}$$

- Les hypothèses testées sont :
    - $H_0 : \beta_j = \beta_{th}$
    - $H_1 : \beta_j \neq \beta_{th}$
- 

## La significativité simple

- Le test consiste souvent à savoir si le paramètre est significativement différent de 0 (  $\beta_{th} = 0$  ).
- La statistique de test devient donc :

$$t_{\beta_j} = \frac{\hat{\beta}_j}{\hat{\sigma}_\beta}$$

- Les hypothèses testées deviennent :
    - $H_0 : \beta_j = 0$
    - $H_1 : \beta_j \neq 0$
-

## La significativité simple

- La statistique de test calculée  $t_{\beta_j}$  est comparée à la statistique théorique  $t_\alpha$  tabulée pour un risque de première espèce  $\alpha$ .
- Remarque : il s'agit en général d'un **test bilatéral**.

```
alpha <- 0.05
df     <- 30
xlim   <- c(-4, 4)
tcrit  <- qt(1 - alpha/2, df = df)

xx <- seq(xlim[1], xlim[2], length.out = 2000)
yy <- dt(xx, df = df)

plot(xx, yy, type = "l", lwd = 2,
      xlab = "t", ylab = "densité",
      main = sprintf("Loi t(%d) - test bilatéral ( = %.2f)", df, alpha),
      xaxt = "n") # on dessine l'axe X nous-mêmes

shade_region <- function(x_from, x_to, col){
  xseq <- seq(x_from, x_to, length.out = 500)
  yseq <- dt(xseq, df = df)
  polygon(c(xseq, rev(xseq)), c(yseq, rep(0, length(yseq))),
          col = col, border = NA)
}

# Colorier les zones
shade_region(-tcrit, tcrit, col = rgb(0.2, 0.6, 1, 0.3)) # zone centrale
shade_region(xlim[1], -tcrit, col = rgb(1, 0.2, 0.2, 0.35)) # queue gauche
shade_region(tcrit, xlim[2], col = rgb(1, 0.2, 0.2, 0.35)) # queue droite

# Traits verticaux
abline(v = c(-tcrit, tcrit), lwd = 2, lty = 2)

# Axe X avec -t* et t* comme graduations
axis(1,
      at = c(xlim[1], -tcrit, 0, tcrit, xlim[2]),
      labels = c("", sprintf("-t* = %.2f", -tcrit), "0", sprintf("t* = %.2f", tcrit), ""),
      tick = TRUE)

# Étiquettes
text(0, max(yy)*0.65, expression(1 - alpha), cex = 1.4)
```

```
# /2 décalés sous l'axe X, vers l'extérieur
text(-tcrit, -0.015, expression(alpha/2), cex = 1.2, pos = 1, offset = 1)
text( tcrit, -0.015, expression(alpha/2), cex = 1.2, pos = 1, offset = 1)

legend("topright",
      legend = c("densité t(df)",
                  "région d'acceptation (1-)",
                  "régions de rejet (/2)"),
      lty = c(1, NA, NA), lwd = c(2, NA, NA),
      pch = c(NA, 15, 15),
      pt.cex = 2,
      col = c("black", rgb(0.2,0.6,1,0.3), rgb(1,0.2,0.2,0.35)),
      bty = "n", cex = 0.9)
```

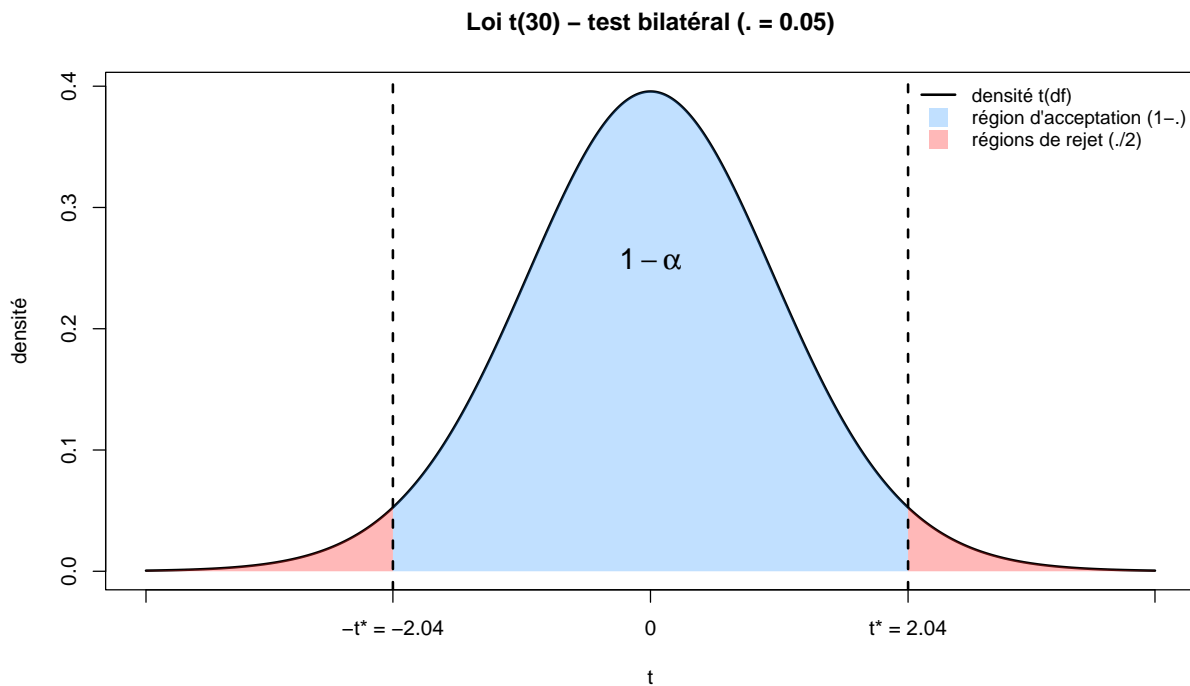


Figure 2: Test bilatéral :  $\alpha/2$  décalés vers l'extérieur,  $-t^*$  et  $t^*$  en graduations de l'axe X.

## La significativité simple — procédure

1. **Calculer** la statistique de Student (Coef / SE) :  $t_{\beta_j} = \hat{\beta}_j / \sigma \hat{\beta}$ .

2. **Choisir** un niveau de risque de première espèce  $\alpha$ .
3. **Déterminer** la valeur critique tabulée  $t_{\alpha/2, \nu}$  pour un **test bilatéral**, avec  $\nu = N - p$  (ddl : nb d'observations  $N$  moins nb de paramètres  $p$ ) .
4. **Conclure** sur la significativité selon la règle de décision :
  - si  $|t| < t_{\alpha/2, \nu} (\Rightarrow)$  non-rejet de  $H_0$
  - si  $|t| \geq t_{\alpha/2, \nu} (\Rightarrow)$  rejet de  $(H_0)$

---

### Tableau de décision test bilatéral

Décision / Réalité	$H_0$ vraie	$H_0$ fausse
Rejeter $H_0$	Erreur $\alpha$	Décision correcte
Ne pas rejeter $H_0$	Décision correcte	Erreur $\beta$

#### Caution

On parle de rejet ou non rejet d'une hypothèse, pas d'acceptation.

---

### La significativité conjointe

#### Tip

Dans un modèle, nous pouvons nous intéresser à déterminer si nos différentes variables ont un effet significatif sur notre variable  $Y$ , dépendamment les unes des autres. C'est à dire, est-ce que mes variables sont significatives *conjointement* (  $X_1$  significative ET  $X_N$  ... )

Dans ce cadre, les simples tests de Student ne sont pas suffisants, pour tester plusieurs restrictions, il faut recourir à d'autres tests:

Test de Fisher dans le cas des modèles linéaires

Tests de Wald, du log de vraisemblance ou du multiplicateurs de Lagrange dans les cas plus complexes

## La significativité conjointe le test de Fisher (F-test)

- Le **F-test** permet de tester la significativité conjointe de plusieurs paramètres, voire la significativité globale d'un modèle linéaire. La statistique de test est la suivante :

$$F = \frac{SCR_r - SCR_{nr}}{SCR_{nr}} \frac{N - p}{q}$$

où :

- $q$  : nombre de restrictions testées (sans la constante),
  - $p$  : nombre de paramètres dans le modèle non restreint (avec la constante),
  - $N$  : nombre d'observations.
  - $SCR_r$  : somme des carrés des résidus du modèle **restreint** (les paramètres imposés sont fixés),
  - $SCR_{nr}$  : somme des carrés des résidus du modèle **non restreint** (modèle usuel non contraint).
- 

## La significativité conjointe — F-test (unilatéral)

- Le test de Fisher est **unilatéral** (rejet dans la **queue droite**).
- Sous ( $H_0$ ), la statistique suit une loi de **Fisher-Snedecor** :  $F \sim F(q, N - p)$  , où  $q$  = nb de restrictions testées et  $N - p$  = ddl résiduels du modèle non restreint.
- Les logiciels (EViews, R, etc.) donnent directement (F), la p-value et la table ANOVA.

```
alpha <- 0.05
q      <- 3
df2    <- 30
Fcrit  <- qf(1 - alpha, df1 = q, df2 = df2)

xmax <- qf(0.999, df1 = q, df2 = df2)
xx   <- seq(0, xmax, length.out = 2000)
yy   <- df(xx, df1 = q, df2 = df2)

plot(xx, yy, type = "l", lwd = 2,
      xlab = "F", ylab = "densité",
      main = sprintf("Loi F(%d, %d) - test unilatéral ( = %.02f)", q, df2, alpha),
      cex.lab = 1.3, cex.axis = 1.2, xaxt = "n")
```

```

shade_region <- function(x_from, col){
  xseq <- seq(x_from, xmax, length.out = 600)
  yseq <- df(xseq, df1 = q, df2 = df2)
  polygon(c(xseq, rev(xseq)), c(yseq, rep(0, length(yseq))),
          col = col, border = NA)
}

# Zones
polygon(c(0, xx[xx <= Fcrit], Fcrit),
        c(0, yy[xx <= Fcrit], 0),
        col = rgb(0.2, 0.6, 1, 0.15), border = NA)
shade_region(Fcrit, col = rgb(1, 0.2, 0.2, 0.35))

abline(v = Fcrit, lwd = 2, lty = 2)

# Axe X plus lisible avec F* bien marqué
axis(1,
     at = c(0, Fcrit, round(xmax,1)),
     labels = c("0",
                bquote(F~"*" == .(round(Fcrit,2))),
                round(xmax,1)),
     cex.axis = 1.2)

# Étiquettes
text(mean(c(0,Fcrit))*0.5, max(yy)*0.5, expression(H[0]), cex = 1.4)
text((Fcrit + xmax)/2, max(yy)*0.25, expression(H[A]), cex = 1.4)
text(Fcrit, par("usr")[3] - 0.02, expression(alpha),
     xpd = NA, pos = 1, cex = 1.3)

legend("topright",
      legend = c("densité F(q, N-p)",
                 "région H0 (non rejet)",
                 "région de rejet ( )"),
      lty = c(1, NA, NA), lwd = c(2, NA, NA),
      pch = c(NA, 15, 15), pt.cex = 2,
      col = c("black", rgb(0.2,0.6,1,0.15), rgb(1,0.2,0.2,0.35)),
      bty = "n", cex = 1)

```




Figure 3: Loi F(3,30) — test unilatéral : étiquettes lisibles.

### La significativité conjointe — hypothèses usuelles du F-test

- On teste généralement la contrainte selon laquelle **tous les coefficients (hors constante) sont nuls**.
  - $H_0$  : tous les coefficients du modèle sont égaux à 0 (sauf l'intercept), c.-à-d.  $H_0 : \beta_1 = \beta_2 = \dots = \beta_p = 0$
  - $H_1$  : **au moins un** coefficient est différent de 0.
- Dans ce cas, le **modèle contraint** est le modèle **avec seule la constante**. **Règle de décision** :  
 si  $F > F_{\text{table}}$  (au niveau  $\alpha$ ) et ddl ( $q, N - p$ )  $\Rightarrow$  **rejet de  $H_0$** .
- **Interprétation** :
  - **Non-rejet de  $H_0$**   $\Rightarrow$  pas de relation linéaire significative entre la variable expliquée et l'ensemble des variables explicatives.
  - Autrement dit, la **SCE** (somme des carrés expliquée) n'est pas significativement différente de 0 ; la variabilité de (Y) demeure essentiellement **aléatoire**.

## La significativité conjointe — F-Test : procédure EViews

- Procédure à suivre :

1. Régresser le modèle **non contraint** et relever la SCR.
  2. Régresser le modèle **contraint** et relever la SCR.
  3. Calculer la statistique de Fisher.
  4. Comparer la valeur obtenue à la valeur théorique (table de Fisher).
- 

## La significativité conjointe — F-Test : Exemple de commandes EViews

```
equation eqnr Y X1 X2 X3 X4 X5 c
scalar scnr = eqnr.@ssr
equation eqr Y X1 X3 c
scalar scrr = eqr.@ssr
scalar F = ((scrr - scnr) / scnr) * ((129 - 5) / 3)
```

Ici :

- **eqnr** : estimation du modèle **non restreint** (toutes les variables).
  - **eqr** : estimation du modèle **restreint**.
  - **scnr** et **scrr** : sommes des carrés des résidus respectivement non restreint et restreint.
  - **F** : statistique de Fisher calculée manuellement.
-



## La significativité conjointe — Wald-test

- La procédure selon le **Wald-test** est pré-enregistrée dans EViews :

1. **Ouvrir** les résultats de l'estimation.
2. **Menu** : View → Coefficient diagnostic → Wald test.
3. **Saisir les contraintes** de la forme :

`c(numéro_coef1) = 0`

`c(numéro_coef2) = 0`

par exemple :

`c(3) = 0`

`c(5) = 0`

---

## Significativité économique

### ! Important

Une variable peut avoir une très grande significativité statistique mais une faible significativité économique. Ici nous ne nous intéressons pas à la “robustesse” de l'estimation de l'effet, mais à sa “magnitude”

L'interprétation du coefficient estimé  $\beta$  dépend de la manière dont **Y** (variable expliquée) et **X** (variable explicative) sont exprimées : en **niveau** ou en **logarithme**.

---

### Significativité économique - un tableau récapitulatif :

Variable expliquée (Y)	Variable explicative (X)	Interprétation du coefficient $\beta$
Niveau	Niveau	Une augmentation de <b>1 unité</b> de X entraîne une variation moyenne de $\beta$ unités de Y.

Variable expliquée (Y)	Variable explicative (X)	Interprétation du coefficient $\beta$
<b>Niveau</b>	<b>Logarithme</b>	Une augmentation de <b>1 %</b> de X entraîne une variation moyenne de $\beta/100$ unités de Y.
<b>Logarithme</b>	<b>Niveau</b>	Une augmentation de <b>1 unité</b> de X entraîne une variation moyenne de $\beta \times 100$ % de Y.
<b>Logarithme</b>	<b>Logarithme</b>	Une augmentation de <b>1 %</b> de X entraîne une variation moyenne de $\beta$ % de Y.

---

## Questions – Réponses TD2 (Module 2)

---

**Question : Importez la base de données sur les compagnies aériennes.**

Afficher la réponse

Menu **File** → **Open** → **Foreign Data as Workfile** puis sélectionner le fichier de données.

---

**Question : Créez le logarithme du nombre de passagers. Quelle est l'utilité de cette transformation ?**

Afficher la réponse

Commande : `genr logpassagers = log(passagers)`

Cette transformation :

- réduit l'impact des valeurs extrêmes en **compressant l'échelle**,
- rapproche la distribution d'une **loi normale**,
- **stabilise les variances**,
- permet une **interprétation en pourcentage** : une variation d'une unité du log une variation d'environ 100 % de la variable d'origine,

- aide à **linéariser les relations** et donc facilite l'usage de la régression linéaire.
- 

**Question : Estimez l'équation suivante par les MCO. Dans quelle mesure cette équation peut-elle être considérée comme linéaire ?**

Afficher la réponse

Menu **Object** → **New Object** → **Equation**, choisir « Linear ».

Même si la variable dépendante est en logarithme, l'équation reste **linéaire** car les variables explicatives apparaissent en **première puissance** et la relation est **additive**.

---

**Question : Distinguez les variables dépendantes, indépendantes, d'intérêt et de contrôle.**

Afficher la réponse

- **Variable dépendante (expliquée)** : logpass (log du nombre de passagers).
  - **Variables explicatives** : Ratio, croissance annuelle du trafic aérien de la destination principale (2010-2013), public, low cost, age, intercontinental, croissance annuelle du trafic aérien du pays d'origine (2010-2013).
  - **Variable d'intérêt** : Ratio.
  - **Variables de contrôle** : toutes les autres variables explicatives listées ci-dessus.
- 

**Question : D'après le  $R^2$  de l'estimation, l'équation a-t-elle un pouvoir explicatif correct ?**

Afficher la réponse

Le  $R^2$  obtenu est 0,39 : le modèle explique environ **40 % de la variabilité** du nombre de passagers.

**pouvoir explicatif modéré**, le modèle reste relativement peu explicatif.

---

**Question : Le nombre d'accidents par passagers est-il significativement différent de zéro ?**

Afficher la réponse

Test de Student bilatéral :

- $|t_{\text{calculé}}| = 3,22 > t_{\alpha/2, N-p} = 1,658$ .  
\* Avec  $N - p = 94 - 8 = 86$ .

**Rejet de ( $H_0$ ) :** le coefficient du nombre d'accidents par passagers est **significativement différent de 0**.

---

**Question : Distinguer entre accidents mortels et non mortels et réestimer l'équation.**

Afficher la réponse

Créer les variables :

`genr Dummy_fatal = fatal>=1 genr Dummy_non_fatal = non_fatal>=1`

Puis relancer la régression en remplaçant `ratio` par les deux nouvelles variables.

---

**Question : Ces variables sont-elles individuellement et conjointement significatives ?**

Afficher la réponse

- **Individuellement :**
    - Accidents mortels :  $|t| = 1,713 > 1,658$  significatif.
    - Accidents non mortels :  $|t| = 1,671 > 1,658$  significatif.
  - **Conjointement (test de Fisher) :**
    - $F_{\text{calculé}} = 6,792 > F_{\text{table}} = 3,07$  **rejet de  $H_0$** ,
    - donc les deux variables sont **conjointement significatives**.
-

**Question : Quelle variable semble la plus importante d'un point de vue économique ?  
Comment interpréter le coefficient obtenu ?**

Afficher la réponse

**Procédure :**

Dans EViews → View → Coefficient diagnostics → Scaled coefficient.

Le **coefficient standardisé** indique de combien d'écarts-types Y varie quand X varie d'un écart-type.

Cela permet de comparer directement l'importance relative des variables.

**Résultat :**

La variable **intercontinentale** a le plus grand coefficient standardisé ( $\sim 0,42$ ).

Comme Y est en logarithme et X en niveau, cela signifie qu'une compagnie qui devient **intercontinentale** augmente en moyenne le nombre de passagers d'environ **10 %**, toutes choses égales par ailleurs.

C'est la variable la plus importante d'un point de vue économique.