Économétrie — TD 9

Simulation de Monte Carlo

Pierre Beaucoral

```
library(knitr)
knit_hooks$set(optipng = hook_optipng)
```

Introduction générale

1.1 Origines de la méthode

> *« The Monte Carlo method … is an invention of statistical sampling for the solution of mathematical problems for which direct methods are not feasible. »* @metropolis1949.

- Le nom **Monte Carlo** fait référence au **casino de Monaco**, symbole du **hasard**.
- Mise en œuvre pour la première fois dans les **années 1940**, durant le **projet Manhattan** en physique nucléaire.
- Objectif initial : approximer des **intégrales complexes** ou des **probabilités** impossibles à calculer analytiquement.

Article original Metropolis & Ulam (1949)

1.2 Idée en économétrie

Une simulation de Monte Carlo est une **expérience de pensée codée sur ordinateur** :

1. **Spécifier un modèle théorique connu** (par exemple une régression linéaire).
2. **Fixer les « vrais » paramètres** et la distribution de l'erreur (normale, ^{2}, etc.).
3. **Générer artificiellement de nombreux échantillons** de données.
4. **Estimer** sur chacun de ces échantillons le même modèle que l'on veut étudier.

5. **Observer empiriquement** la distribution des estimateurs : biais, variance, forme, robustesse des tests.

> **Tip**
>
> La simulation de Monte Carlo agit comme un **laboratoire virtuel** : elle permet de vérifier et d'illustrer les propriétés théoriques des estimateurs quand la démonstration analytique est complexe ou quand on veut observer leur comportement "en pratique".

---

2. Mise en œuvre pratique

2.1 Étapes générales d'une simulation

- Fixer la taille d'échantillon n et le nombre de répliques R.
- Définir le modèle :

$$y_i = \alpha + \beta x_i + \varepsilon_i$$

  avec par exemple $\varepsilon_i \sim \mathcal{N}(0, 1)$.
- Pour chaque réplication $r = 1, \ldots, R$:
  1. Générer les x_i et les erreurs ε_i.
  2. Calculer y_i.
  3. Estimer $(\hat{\alpha}_r, \hat{\beta}_r)$ par MCO.
- Analyser la distribution empirique des $\hat{\beta}_r$: moyenne, variance, skewness, kurtosis, comparaison à la valeur vraie β.

2.2 Commandes EViews utiles

Action	Commande
Générer une normale centrée réduite	`series e = nrnd`
Générer une loi ^{2}(v)	`series e = @rchisq(v)`
Créer une variable simulée	`series y1 = 7 + 0.4*lsize + 0.8*bed + 0.2*bath + 0.2*airco + e`
Estimer par MCO	`ls y1 c lsize bed bath airco`
Lancer un programme	`run Montecarlo.prg`

---

3. Exemple R : animation de la convergence

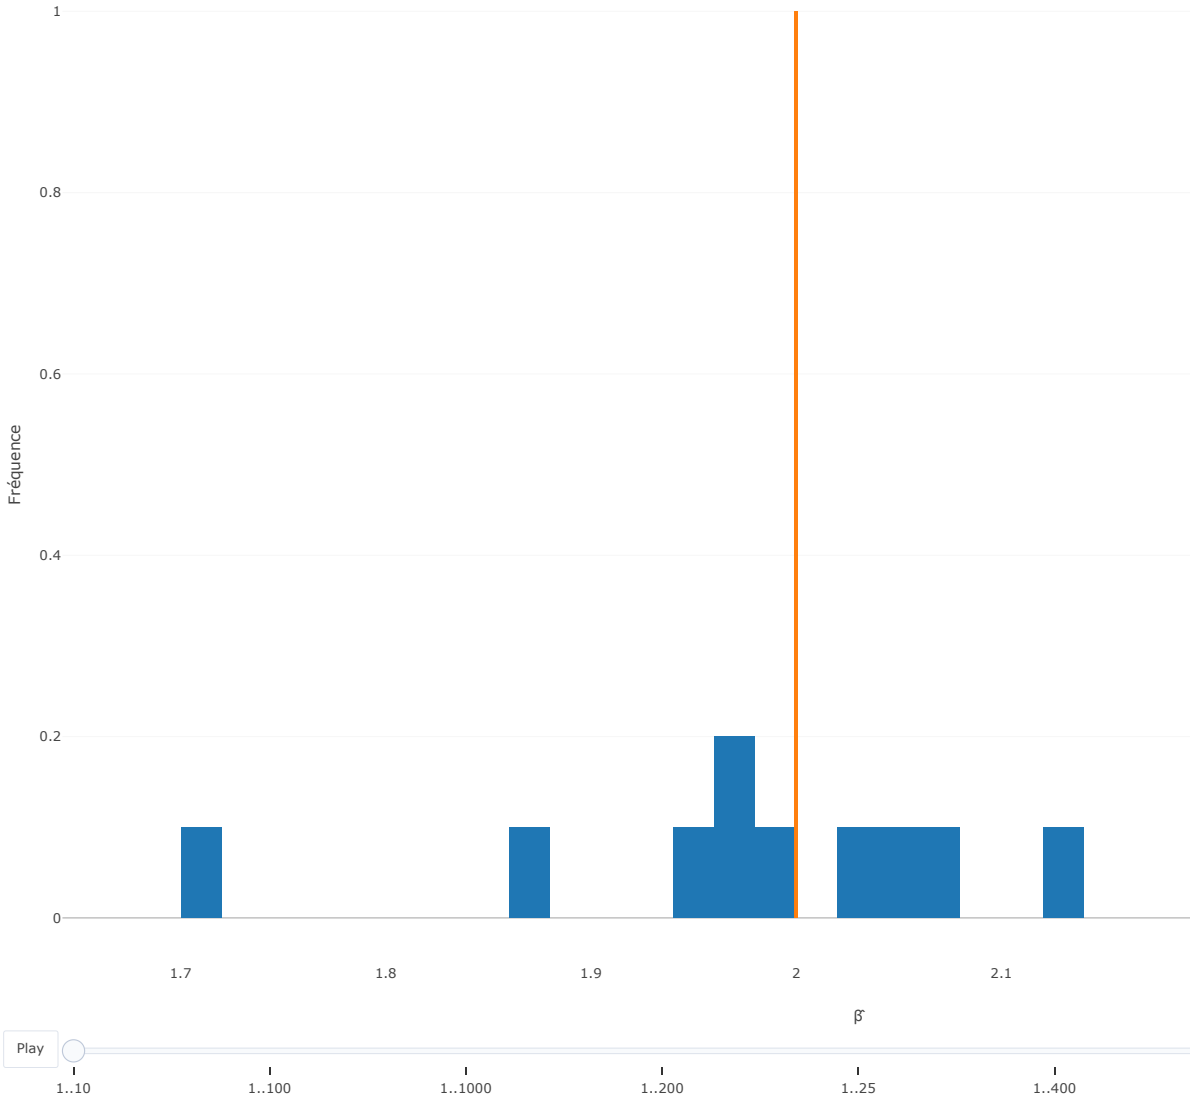

Figure 1: Histogramme cumulatif des estimateurs de (vraie valeur = 2).

Ce graphique illustre la **loi des grands nombres** : à mesure que le nombre d'itérations augmente, l'histogramme des $\hat\beta$ se resserre autour de la vraie valeur $\beta = 2$.

Questions du TD et réponses détaillées

Q1 — Générer y1 et estimer

> En supposant $\varepsilon \sim \mathcal{N}(0,1)$, générez une série **y1** et estimezl'équation par MCO.

Afficher la réponse

EViews :

```
series e = nrnd
series y1 = 7 + 0.4*lsize + 0.8*bed + 0.2*bath + 0.2*airco + e
ls y1 c lsize bed bath airco
```

Les coefficients estimés doivent être proches des valeurs vraies (0.4, 0.8, 0.2, 0.2) avec de légères fluctuations aléatoires.

Q2 — Répéter y2…y5

> Refaire la Q1 pour **y2** à **y5**, même modèle, nouvelles erreurs.

Afficher la réponse

Même démarche en changeant le nom de la série (`y2`, `y3` …). Comparer les $\hat{\beta}$ obtenus : on doit observer une dispersion autour des valeurs vraies, illustrant la **variabilité d'échantillonnage**.

Q3 — Programme Monte Carlo

> Ouvrez `Montecarlo.prg`, exécutez-le. Les coefficients sont enregistrés dans la matrice `resultat`. Faites un histogramme et calculez moyenne, variance, skewness, kurtosis.

Afficher la réponse

```
run Montecarlo.prg
```

Puis `View → Descriptive Statistics → Histogram & Stats` sur chaque colonne de `resultat`.
Les estimateurs doivent avoir :

- une moyenne proche du vrai paramètre (absence de biais),
- une variance reflétant la précision,
- skewness 0 et kurtosis 3 si les erreurs sont normales.

Q4 — 1000 itérations

Appliquer la même procédure avec **1000** itérations.

Afficher la réponse

Dans `Montecarlo.prg`, modifier :

```
!nbiter = 1000
```

et exécuter.

La moyenne des $\widehat{\beta}$ se rapproche encore plus de la valeur vraie,

et la variance estimée se stabilise — illustration de la **loi des grands nombres**.

Q5 — Variance d'erreur différente

Refaire 1–4 en supposant $\varepsilon \sim \mathcal{N}(0, 0.625)$, 1000 puis 5000 simulations.

Afficher la réponse

```
series e = sqrt(0.625)*nrnd
```

Une variance d'erreur plus faible des estimateurs plus précis (variance plus faible).
Avec 5000 simulations, l'évaluation des moments (moyenne, variance, skewness, kurtosis) devient plus stable.

Q6 — Erreurs non normales

Refaire 1–4 avec $\varepsilon \sim \chi^2(7)$, 1000 puis 5000 simulations.

Afficher la réponse

```
series e = @rchisq(7)
```

La distribution est asymétrique (skewness > 0). Les MCO restent **asymptotiquement sans biais**, mais les tests t/F, fondés sur la normalité, peuvent avoir un **risque de première espèce mal calibré**.

Utiliser des **erreurs-types robustes** (White, HAC) ou des tests non paramétriques pour l'inférence.

---

5. Points clés à retenir

- La **simulation de Monte Carlo** est un outil de validation empirique : elle confirme les propriétés théoriques des estimateurs et permet de tester la robustesse des procédures statistiques.
- Les estimateurs MCO restent sans biais même si les erreursne sont pas normales, mais l'inférence (tests t/F) peut devenir peu fiable en petit échantillon.
- En cas de non-normalité, recourir à des **erreurs-types robustes** ou à des méthodes d'inférence alternatives (bootstrap, tests non paramétriques).