

TD 1 : Modèle de Poisson (R)

Années universitaires 2025–2026 et 2026–2027 ■ Parcours Économie de la santé
& Développement durable

Pierre Beaucoral

Contexte: On étudie d'anciennes données reliant **tabagisme** et **décès par cancer du poumon**. Variables : **age** (classes), **smoking status** (4 classes), **population** (centaines de milliers), **deaths** (décès annuels).

Préparation

Objectifs de ce TD

- Importer et préparer un tableau **comptages + exposition** (population à risque).
- Ajuster un **GLM Poisson** avec *offset* (log-exposition).
- Évaluer l'ajustement : **déviance** (vs modèle saturé) & **Pearson**.
- Comparer des modèles via **tests de rapport de vraisemblance (LR)**.
- Interpréter en **ratios de taux d'incidence (IRR)** et produire des **comptes attendus**.

Packages

```
# installer si nécessaire : install.packages(c("readxl","dplyr","tidyr","janitor","ggplot2",  
library(readxl)  
library(dplyr)  
library(tidyr)  
library(janitor)  
library(ggplot2)  
library(broom)  
library(gt)  
library(performance) # check_overdispersion  
library(DescTools)   # PChisq for GOF (si besoin)
```

```
# Formatage des nombres dans le texte (virgule décimale, p-values)
fr    <- function(x, d = 2) formatC(x, format = "f", digits = d, decimal.mark = ",")
fmt_p <- function(p) if (p < 0.001) "< 0,001" else paste("=", fr(p, 3))
```

i Rappel de cours : Régression de Poisson

La **régression de Poisson** est un modèle linéaire généralisé (GLM) adapté aux données de **comptage** (ex. nombre de décès, d'accidents, de visites).

Formulation :

- Variable dépendante : un comptage $Y_i \in \{0, 1, 2, \dots\}$. - Loi supposée : $Y_i \sim \text{Poisson}(\mu_i)$ avec $\mathbb{E}[Y_i] = \mu_i$.
- Lien log :

$$\log(\mu_i) = \beta_0 + \beta_1 X_{1i} + \dots + \beta_p X_{pi} + \log(\text{exposition}_i)$$
où l'offset $\log(\text{exposition}_i)$ tient compte de la taille de la population ou du temps d'observation.

Pourquoi utiliser ce modèle ?

- Les données sont des comptages positifs (non négatifs).
- La variance est proportionnelle à la moyenne ($\text{Var}(Y) = \mu$).
- On cherche à modéliser des **taux d'incidence** (décès/population, accidents/temps).

Interprétation des coefficients :

- Les β_j s'interprètent via l'**Incidence Rate Ratio (IRR)** :

$$IRR_j = e^{\beta_j}$$

→ $IRR_j > 1$: le taux est plus élevé que la référence.

→ $IRR_j < 1$: le taux est plus faible.

Diagnostics courants :

- Tests de qualité d'ajustement (déviante, Pearson).
- Vérification de la sur-dispersion (si $\text{Var}(Y) > \mu$, préférer quasi-Poisson ou binomiale négative).

Extensions :

- Modèle de Poisson avec offset (exposition).
- Quasi-Poisson pour corriger la variance.
- Binomiale négative pour sur-dispersion forte.

Import et manipulation des données

Importer les données `smoking_dat.xlsx`

[Télécharger `smoking\_dat.xlsx`](#)

Dans l'énoncé, les données à importer sont `smoking_dat.xlsx` et les variables `age`, `smoking status`, `population`, `deaths`.

Note

Dictionnaire des variables :

- `age`: en classes (40-44, 45-49, 50-54, 55-59, 60-64, 65-69, 70-74, 75-79, 80+).
- `smoking status`: 4 classes (ne fume pas / fume le cigare ou la pipe / fume la cigarette et le cigare ou la pipe ; fume seulement la cigarette)
- `population`: en centaine de milliers de personnes
- `deaths`: comptage des décès par cancer du poumon en un an.

```
# Chemin suggéré : placez le fichier dans data/smoking_dat.xlsx
# Si vous avez un CSV, remplacez read_excel par read_csv(...)
data_path <- "data/smoking_dat.xlsx"

df <- read_excel(data_path) |>
  clean_names()

# Harmonisation de noms
# On s'attend à des colonnes: age (classes), smoking_status (4 classes), population, deaths
df <- df |>
  rename(
    age = matches("^age$|^age_class|^agecat"),
    smoking_status = matches("^smoking|^smoke"),
    population = matches("^pop|^population"),
    deaths = matches("^deaths|^dead")
  )

glimpse(df)
```

Rows: 36

Columns: 4

\$ age <chr> "40-44", "45-59", "50-54", "55-59", "60-64", "65-69", "~

\$ smoking_status <chr> "no", "no", "no", "no", "no", "no", "no", "no", "no", "~

```
$ population      <dbl> 656, 359, 249, 632, 1067, 897, 668, 361, 274, 145, 104, ~
$ deaths          <dbl> 18, 22, 19, 55, 117, 170, 179, 120, 120, 2, 4, 3, 38, 1~
```

Coder les deux variables enregistrées en texte avec des chiffres

En Stata on ferait `encode + i.variable`.

En R, il suffit de déclarer les variables comme `factor`.

```
df <- df |>
  mutate(
    age = factor(age, ordered = FALSE),
    smoking_status = factor(smoking_status, ordered = FALSE)
  )

# Vérification des niveaux
levels(df$age); levels(df$smoking_status)
```

```
[1] "40-44" "45-59" "50-54" "55-59" "60-64" "65-69" "70-74" "75-79" "80+"
```

```
[1] "cigarPipeOnly" "cigaretteOnly" "cigarettePlus" "no"
```

Note

Rappel : Les facteurs indiquent à R qu'il s'agit de variables qualitatives. Chaque modalité sera transformée en **variable indicatrice** (dummy) dans la régression.

Unité d'exposition

L'énoncé précise que `population` est en **centaines de milliers**. Pour une interprétation plus intuitive, on peut ramener l'exposition à l'unité **personne** (facultatif) :

```
# Ici, on transforme 'population' en nombre de personnes si besoin.
# Exemple: si population = 2.3 signifie 2.3 * 100 000 personnes :
expo_personnes <- TRUE
scale_factor <- 1e5

df <- df |>
  mutate(
    exposure = if (expo_personnes) population * scale_factor else population
```

```
)  
summary(df$exposure)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
9800000	36925000	85850000	155894444	230550000	605200000

Estimations

Appliquer un premier modèle de régression log-linéaire

Modèle Poisson **log-linéaire** avec effets de `smoking_status` et `age`, et *offset* `log(exposure)` : c'est l'équivalent de Stata `poisson deaths i.smokecod i.agecod, exposure(pop)`.

💡 Tip

Pourquoi un modèle de Poisson ?

Les données sont des **comptages** (nombre de décès).

Le modèle de Poisson relie l'**espérance** de ces comptages à des variables explicatives par une fonction de lien log :

$$\log(\mathbb{E}[Y]) = X\beta$$

Cette structure garantit que la prédiction est **positive** et que la variance est proportionnelle à la moyenne (hypothèse de Poisson).

Nous voulons expliquer le nombre de décès par l'âge et le statut tabagique, en tenant compte de l'exposition.

```
mod1 <- glm(deaths ~ smoking_status + age + offset(log(exposure)),  
            family = poisson(link = "log"), data = df)  
  
summary(mod1)
```

Call:

```
glm(formula = deaths ~ smoking_status + age + offset(log(exposure)),  
     family = poisson(link = "log"), data = df)
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-15.14514	0.06783	-223.293	< 2e-16 ***
smoking_statuscigaretteOnly	0.36915	0.03791	9.737	< 2e-16 ***
smoking_statuscigarettePlus	0.17015	0.03643	4.671	3.00e-06 ***
smoking_statusno	-0.04781	0.04699	-1.017	0.309
age45-59	0.55388	0.07999	6.924	4.38e-12 ***
age50-54	0.98039	0.07682	12.762	< 2e-16 ***
age55-59	1.37946	0.06526	21.138	< 2e-16 ***
age60-64	1.65423	0.06257	26.439	< 2e-16 ***
age65-69	1.99817	0.06279	31.824	< 2e-16 ***
age70-74	2.27141	0.06435	35.296	< 2e-16 ***
age75-79	2.55858	0.06778	37.746	< 2e-16 ***
age80+	2.84692	0.07242	39.310	< 2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for poisson family taken to be 1)

Null deviance: 4055.984 on 35 degrees of freedom
 Residual deviance: 21.487 on 24 degrees of freedom
 AIC: 285.51

Number of Fisher Scoring iterations: 4

! Important

L'argument `offset(log(exposure))` ajoute le **log de l'exposition** avec un coefficient fixé à 1. Cela revient à modéliser un **taux** de décès (décès / population).

Quelle interprétation?

On peut utiliser $\exp(\beta_i)$ pour retrouver l'**Incidence Rate Ratio (IRR)**. On le lit comme le coefficient multiplicateur de l'occurrence de Y (ici le décès) par rapport à la catégorie de référence.

Calculer la déviance du modèle ajusté. DEV1

```
dev1 <- deviance(mod1)      # Deviance du modèle vs saturé
df_dev1 <- df.residual(mod1)
c(dev1 = dev1, df = df_dev1, p_value = pchisq(dev1, df_dev1, lower.tail = FALSE))
```

dev1	df	p_value
------	----	---------

IRR de l'âge (référence : 40-44 ans)

age	IRR	ic_bas	ic_haut
45-59	1.74	1.49	2.04
50-54	2.67	2.29	3.10
55-59	3.97	3.50	4.51
60-64	5.23	4.63	5.91
65-69	7.38	6.52	8.34
70-74	9.69	8.54	11.00
75-79	12.92	11.31	14.75
80+	17.23	14.95	19.86

21.486738 24.000000 0.609872

Réponse. La déviance du modèle ajusté vaut **DEV1 = 21,49** pour **24 degrés de liberté**. La déviance mesure l'écart entre notre modèle et le modèle **saturé** (un paramètre par cellule, qui reproduit exactement les données) : $DEV = 2 [\ell(\text{saturé}) - \ell(\text{modèle})]$. Une déviance proche de son nombre de degrés de liberté (ici 21,49 pour 24) indique déjà un bon ajustement ; on le teste formellement plus bas.

Quel est l'effet de l'âge sur la probabilité de décès par cancer du poumon ?

```
irr1 <- exp(coef(mod1))
ci1 <- exp(confint.default(mod1)) # IC 95 % de Wald, exponentiés

tibble(age = levels(df$age)[-1],
       IRR = irr1[paste0("age", age)],
       ic_bas = ci1[paste0("age", age), 1],
       ic_haut = ci1[paste0("age", age), 2]) |>
  gt() |>
  fmt_number(columns = -age, decimals = 2) |>
  tab_header(title = "IRR de l'âge (référence : 40-44 ans)")
```

Réponse. L'âge est le déterminant **le plus fort** de la mortalité par cancer du poumon. Tous les coefficients d'âge sont positifs et hautement significatifs ($p < 0,001$), et les IRR **croissent de façon monotone** avec la classe d'âge. À statut tabagique donné, et par rapport aux 40-44 ans, le taux de décès est multiplié par :

- **1,74** chez les 45-49 ans ;

- **5,23** chez les 60-64 ans ;
- **17,2** chez les 80 ans et plus (IC 95 % : 15,0 à 19,9).

Autrement dit, d'une classe quinquennale à la suivante, le taux augmente d'environ 30 à 50 % (+74 % entre les deux premières classes). Ce gradient reflète l'accumulation de l'exposition et le temps de latence du cancer du poumon.

Note

À noter. Le fichier nomme la 2^e classe 45-59 : c'est une coquille pour **45-49**, puisque la classe suivante est 50-54. Par ailleurs, l'intercept dépend de l'unité choisie pour l'exposition (la constante vaut le log du taux de la cellule de référence), alors que les IRR n'en dépendent pas. Ce sont eux qu'on interprète.

Sauvegarde du modèle (utile pour LR tests)

```
# En R, on garde l'objet en mémoire (mod1). Pas besoin d'"estimates store".
# On peut aussi l'ajouter à une liste si on veut gérer plusieurs modèles :
models <- list(mod1 = mod1)
```

Tester l'ajustement de ce modèle

Pour cela nous allons réaliser **deux tests** :

- **Deviance GOF** (modèle ajusté vs saturé).
- **Pearson GOF** (comparaison effectifs attendus vs observés). Les **degrés de liberté** correspondent ici au nombre de cellules moins le nombre de paramètres estimés (y compris l'interception). L'énoncé suggère **24 df** pour chacun de ces tests (voir justification plus bas).

```
# Deviance test (déjà calculé ci-dessus)
dev_stat <- deviance(mod1)
dev_df   <- df$residual(mod1)
dev_p    <- pchisq(dev_stat, dev_df, lower.tail = FALSE)

# Pearson GOF (somme (y - mu)^2 / mu) et chi2 approx avec mêmes df résiduels)
mu_hat   <- fitted(mod1)           # comptages attendus
y_obs    <- df$deaths
pearson  <- sum((y_obs - mu_hat)^2 / mu_hat)
```

test	statistic	df	p_value
Deviance GOF	21.48674	24	0.6098720
Pearson GOF	20.61936	24	0.6610658

```
pearson_p <- pchisq(pearson, dev_df, lower.tail = FALSE)

tibble(
  test = c("Deviance GOF", "Pearson GOF"),
  statistic = c(dev_stat, pearson),
  df = c(dev_df, dev_df),
  p_value = c(dev_p, pearson_p)
) |>
  gt()
```

Réponse. Les deux tests concluent au **bon ajustement** du modèle :

- **Déviance** : $G^2 = 21,49$, 24 df, $p = 0,610$;
- **Pearson** : $X^2 = 20,62$, 24 df, $p = 0,661$.

Les hypothèses testées sont :

- H_0 : le modèle reproduit les données aussi bien que le modèle saturé (les écarts observés – attendus sont dus au hasard) ;
- H_1 : le modèle est mal spécifié (il manque des effets, par exemple une interaction âge $\times$ tabac).

Les deux p-values sont largement supérieures à 0,05 : on **ne rejette pas H_0** . Un modèle **additif** (effets de l'âge et du tabac qui se multiplient sur le taux) suffit donc à décrire les 36 cellules, et il n'est pas nécessaire d'ajouter une interaction âge $\times$ tabac.

! Important

Attention au sens du test : ici, c'est une p-value **élevée** qui rassure. Ne pas rejeter H_0 veut dire que les données ne contredisent pas le modèle ; cela ne prouve pas qu'il est « vrai ».

Justifiez pourquoi ces tests sont effectués avec le même df.

```
c(cellules = nrow(df), parametres = length(coef(mod1)),
  df = nrow(df) - length(coef(mod1)),
  cellules_mu_inf_5 = sum(mu_hat < 5), mu_min = min(mu_hat))
```

cellules	parametres	df	cellules_mu_inf_5
36.00000	12.00000	24.00000	2.00000
mu_min			
3.83633			

Réponse. Les deux statistiques comparent **la même chose** : les comptages observés y_i et les comptages ajustés $\hat{\mu}_i$ du même modèle, sur les mêmes cellules. La déviance le fait par un rapport de vraisemblances, $G^2 = 2 \sum_i y_i \log(y_i/\hat{\mu}_i) - (y_i - \hat{\mu}_i)$, et Pearson par des écarts au carré normalisés, $X^2 = \sum_i (y_i - \hat{\mu}_i)^2/\hat{\mu}_i$. Ce sont deux approximations asymptotiques équivalentes du même test (modèle contre modèle saturé), qui suivent sous H_0 la même loi $\chi^2(N - p)$:

- $N = 36$ cellules (9 classes d'âge $\times$ 4 statuts tabagiques), soit les paramètres du modèle saturé ;
- $p = 12$ paramètres estimés (1 constante + 3 indicatrices tabac + 8 indicatrices âge) ;
- d'où **df** = **36** − **12** = **24**, ce qui correspond aux 24 df de l'énoncé.

Condition de validité : l'approximation ² demande des effectifs attendus suffisants (règle usuelle $\hat{\mu}_i \geq 5$). Ici, seules 2 cellules sur 36 ont $\hat{\mu}_i < 5$ (minimum 3,84) : ce sont les fumeurs de cigare/pipe de 40-44 et 45-49 ans, des cellules à faible effectif. On peut donc se fier à l'approximation, et les deux statistiques sont d'ailleurs très proches.

Ajuster un modèle sans la variable smoke, et effectuer un test de rapport de vraisemblance entre ce nouveau modèle et celui précédemment sauvegardé

On ajuste un modèle **sans tabac** et on compare à mod1 par **LR test**. En Stata : `lrtest`. En R : `anova(mod0, mod1, test="Chisq")`.

```
mod0 <- glm(deaths ~ age + offset(log(exposure)),
            family = poisson, data = df)

lr01 <- anova(mod0, mod1, test = "Chisq")
lr01
```

Analysis of Deviance Table

Model 1: deaths ~ age + offset(log(exposure))

```

Model 2: deaths ~ smoking_status + age + offset(log(exposure))
  Resid. Df Resid. Dev Df Deviance Pr(>Chi)
1         27      191.723
2         24       21.487  3    170.24 < 2.2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```

Réponse. Le test du rapport de vraisemblance compare deux modèles **emboîtés** : `mod0` (âge seul) est un cas particulier de `mod1` (âge + tabac), obtenu en imposant que les 3 coefficients du tabac soient nuls. La statistique est la différence des déviations, $LR = DEV_0 - DEV_1 = 170,24$, qui suit sous H_0 un $\chi^2(3)$. La p-value est $< 0,001$: on **rejette nettement H_0** . En plus, `mod0` s'ajuste mal à lui seul (déviante 191,72 pour 27 df), alors que `mod1` s'ajuste bien.

Conclure sur l'impact de l'usage du tabac sur la probabilité de décès par cancer du poumon.

Réponse. Le statut tabagique a un effet **significatif** sur la mortalité par cancer du poumon, même à âge donné. Le test LR indique **que** le tabac compte, mais pas **dans quel sens** : pour cela, il faut lire les coefficients.

Warning

Catégorie de référence. R prend la première modalité par ordre alphabétique, ici `cigarPipeOnly` (cigare ou pipe seulement), et non les non-fumeurs. Les IRR ci-dessous se lisent donc **par rapport aux fumeurs de cigare/pipe**. Pour prendre les non-fumeurs comme référence : `df$smoking_status <- relevel(df$smoking_status, ref = "no")`.

À âge égal, par rapport aux fumeurs de cigare/pipe seulement :

- **cigarette seulement** : taux multiplié par **1,45** (+ 45 %, IC 95 % 1,34 à 1,56) ;
- **cigarette + cigare/pipe** : $\times$ **1,19** (IC 95 % 1,10 à 1,27) ;
- **non-fumeurs** : $\times$ **0,95**, différence **non significative** ($p = 0,309$).

Par rapport aux **non-fumeurs**, il suffit de faire le rapport des IRR : les fumeurs de cigarettes seules ont un taux 1,52 fois plus élevé (+ 52 %). **Conclusion** : fumer des cigarettes augmente nettement le risque de décès par cancer du poumon, alors que le cigare ou la pipe seuls ne se distinguent pas des non-fumeurs dans ces données.

Construire une nouvelle variable qui prend la valeur 1 si l'individu fume des cigarettes, 0 s'il n'en fume pas.

Créer une variable `cigarette_user` égale à 1 si l'individu fume des cigarettes, 0 sinon : l'énoncé demande de distinguer le type de produit et de concentrer l'attention sur la **cigarette**.

```
# Adaptez le motif à vos libellés (ex.: "fume seulement la cigarette", "cigarette + cigare/p...
# On classera 1 si l'étiquette contient "cigarette", 0 sinon.
df <- df |>
  mutate(
    cigarette_user = as.integer(grepl("cigarette", tolower(as.character(smoking_status)))))
table(df$cigarette_user, df$smoking_status)
```

	cigarPipeOnly	cigaretteOnly	cigarettePlus	no
0	9	0	0	9
1	0	9	9	0

Réponse. Le tableau croisé sert de vérification : `cigarette_user` vaut 1 pour les deux modalités qui contiennent la cigarette (`cigaretteOnly`, `cigarettePlus`) et 0 pour `no` et `cigarPipeOnly`, soit 18 cellules de chaque côté. Le motif "cigarette" reprend l'orthographe du fichier (avec deux *r*) : un motif "cigarette" ne trouverait aucune ligne, et tout le monde serait codé 0.

Ajuster un troisième modèle avec effet de l'âge et de cette variable d'usage de la cigarette.

```
mod2 <- glm(deaths ~ cigarette_user + age + offset(log(exposure)),
            family = poisson, data = df)
summary(mod2)
```

Call:

```
glm(formula = deaths ~ cigarette_user + age + offset(log(exposure)),
    family = poisson, data = df)
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-15.15590	0.06378	-237.625	< 2e-16 ***
cigarette_user	0.26910	0.02757	9.762	< 2e-16 ***
age45-59	0.55342	0.07999	6.919	4.56e-12 ***
age50-54	0.98480	0.07682	12.820	< 2e-16 ***
age55-59	1.37640	0.06526	21.092	< 2e-16 ***
age60-64	1.64629	0.06256	26.317	< 2e-16 ***
age65-69	1.99023	0.06277	31.708	< 2e-16 ***
age70-74	2.26143	0.06432	35.161	< 2e-16 ***
age75-79	2.54560	0.06766	37.626	< 2e-16 ***
age80+	2.82907	0.07215	39.211	< 2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for poisson family taken to be 1)

Null deviance: 4055.984 on 35 degrees of freedom
Residual deviance: 92.237 on 26 degrees of freedom
AIC: 352.26

Number of Fisher Scoring iterations: 4

```
anova(mod2, test = "Chisq")
```

Analysis of Deviance Table

Model: poisson, link: log

Response: deaths

Terms added sequentially (first to last)

	Df	Deviance	Resid. Df	Resid. Dev	Pr(>Chi)
NULL			35	4056.0	
cigarette_user	1	58.3	34	3997.6	2.195e-14 ***
age	8	3905.4	26	92.2	< 2.2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```
irr2 <- exp(coef(mod2))["cigarette_user"]
ci2 <- exp(confint.default(mod2))["cigarette_user", ]
```

Réponse. À âge égal, les fumeurs de cigarettes (seules ou avec cigare/pipe) ont un taux de décès multiplié par **1,31** par rapport aux autres (IC 95 % 1,24 à 1,38, $p < 0,001$). L'effet est significatif, mais ce modèle **s'ajuste mal** : sa déviance résiduelle vaut 92,24 pour 26 df ($p < 0,001$), contre 21,49 pour 24 df pour mod1. En regroupant les modalités, on perd de l'information. Le test suivant le confirme.

Comparer ce modèle avec le modèle initial par un test de rapport de vraisemblance

On compare le **modèle multiniveaux par type de tabac** (mod1) avec le **modèle binaire cigarette vs non** (mod2).

```
lr21 <- anova(mod2, mod1, test = "Chisq")
lr21
```

Analysis of Deviance Table

```
Model 1: deaths ~ cigarette_user + age + offset(log(exposure))
Model 2: deaths ~ smoking_status + age + offset(log(exposure))
  Resid. Df Resid. Dev Df Deviance Pr(>Chi)
1         26      92.237
2         24      21.487  2      70.75 4.334e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Réponse. mod2 est emboîté dans mod1 : il revient à imposer $\beta_{\text{cigOnly}} = \beta_{\text{cigPlus}}$ et $\beta_{\text{no}} = \beta_{\text{cigarPipe}} = 0$, soit **2 contraintes** (mod1 a 12 paramètres, mod2 en a 10). La statistique vaut $LR = 70,75$ pour 2 df, avec $p < 0,001$: on **rejette** le modèle simplifié. La variable binaire « cigarette oui/non » est **très grossière** : les deux groupes qu'elle fusionne n'ont pas le même risque.

Le type de produit fumé semble-t-il influencer la probabilité de décès par cancer du poumon ?

En Poisson log-linéaire : $IRR = \exp(\text{coef})$. On reporte aussi des **IC 95%** exponentiés.

IRR (modèle 1) : exp(coef) avec IC 95%

term	estimate	conf.low	conf.high	p.value
age80+	1.723470e+01	1.496968e+01	1.988626e+01	0.000000e+00
age75-79	1.291740e+01	1.132626e+01	1.477500e+01	8.819244e-312
age70-74	9.693017e+00	8.558760e+00	1.101560e+01	6.852385e-273
age65-69	7.375556e+00	6.533324e+00	8.357251e+00	2.978913e-222
age60-64	5.229045e+00	4.633991e+00	5.922596e+00	4.943059e-154
age55-59	3.972749e+00	3.501347e+00	4.522490e+00	3.581870e-99
age50-54	2.665487e+00	2.294116e+00	3.100656e+00	2.658489e-37
age45-59	1.739985e+00	1.487796e+00	2.036040e+00	4.376858e-12
smoking_statuscigaretteOnly	1.446509e+00	1.343418e+00	1.558691e+00	2.099342e-22
smoking_statuscigarettePlus	1.185481e+00	1.104252e+00	1.273769e+00	3.001586e-06
smoking_statusno	9.533182e-01	8.692799e-01	1.045138e+00	3.090007e-01
(Intercept)	2.645745e-07	2.312255e-07	3.016715e-07	0.000000e+00

```
tidy(mod1, conf.int = TRUE, exponentiate = TRUE) |>
  select(term, estimate, conf.low, conf.high, p.value) |>
  arrange(desc(estimate)) |>
  gt() |>
  tab_header(title = "IRR (modèle 1) : exp(coef) avec IC 95%")
```

Réponse. Oui, le type de produit compte. Trois constats (référence : cigare/pipe seulement, à âge égal) :

1. **La cigarette est le produit le plus nocif.** Les fumeurs de cigarettes seules ont le taux le plus élevé (IRR = 1,45, soit 1,52 fois celui des non-fumeurs).
2. **Cigare et pipe seuls ne se distinguent pas des non-fumeurs.** L'IRR des non-fumeurs par rapport au cigare/pipe (0,95) n'est pas significativement différent de 1, et son IC contient 1.
3. **Les fumeurs mixtes (cigarette + cigare/pipe)** ont un risque intermédiaire (IRR = 1,19), significativement plus faible que celui des fumeurs de cigarettes seules : les IC ne se recouvrent pas. Une explication possible : ces fumeurs remplacent une partie de leurs cigarettes par le cigare ou la pipe, et consomment donc moins de cigarettes.

C'est pour cela que le test précédent rejette `mod2` : il met dans le même groupe les fumeurs de cigarettes seules et les fumeurs mixtes, dont les risques diffèrent, et dans un autre groupe les non-fumeurs et les fumeurs de cigare/pipe, dont les risques sont proches. Le second regroupement est acceptable, le premier ne l'est pas.

i Note

Ces données sont **observationnelles** : les IRR décrivent des associations ajustées sur l'âge. On ne contrôle ni l'intensité de la consommation (nombre de cigarettes par jour), ni sa durée, ni d'autres facteurs de confusion.

Extensions

Comptes attendus & tableau Observé vs Attendu

```
df_preds <- df |>
  mutate(
    y_obs = deaths,
    mu_hat = fitted(mod1)
  )

df_preds |>
  select(age, smoking_status, exposure, y_obs, mu_hat) |>
  arrange(age, smoking_status) |>
  gt() |>
  fmt_number(columns = c(exposure, y_obs, mu_hat), decimals = 2)
```

```
res_pearson <- residuals(mod1, type = "pearson")
```

Lecture. Les comptages attendus $\hat{\mu}_{ij}$ sont très proches des comptages observés dans toutes les cellules. Les résidus de Pearson, $(y - \hat{\mu})/\sqrt{\hat{\mu}}$, sont tous compris entre -2,00 et 1,57. Seule la cellule des non-fumeurs de 60-64 ans atteint tout juste -2 (un peu moins de décès que prévu), ce qui est attendu par hasard sur 36 cellules : pas de cellule franchement mal prédite. Le modèle additif âge + tabac ne présente donc pas d'écart systématique, ce qui est cohérent avec les tests d'ajustement.

Vérification d'éventuelle sur-dispersion

Le GLM Poisson suppose $\text{Var}(Y) = E[Y]$. Si $\text{Var}(Y) \gg E[Y]$, la **sur-dispersion** peut invalider les tests usuels (SE sous-estimés).

age	smoking_status	exposure	y_obs	mu_hat
40-44	cigarPipeOnly	14,500,000.00	2.00	3.84
40-44	cigaretteOnly	341,000,000.00	124.00	130.50
40-44	cigarettePlus	453,100,000.00	149.00	142.11
40-44	no	65,600,000.00	18.00	16.55
45-59	cigarPipeOnly	10,400,000.00	4.00	4.79
45-59	cigaretteOnly	223,900,000.00	140.00	149.10
45-59	cigarettePlus	303,000,000.00	169.00	165.36
45-59	no	35,900,000.00	22.00	15.76
50-54	cigarPipeOnly	9,800,000.00	3.00	6.91
50-54	cigaretteOnly	185,100,000.00	187.00	188.82
50-54	cigarettePlus	226,700,000.00	193.00	189.53
50-54	no	24,900,000.00	19.00	16.74
55-59	cigarPipeOnly	37,200,000.00	38.00	39.10
55-59	cigaretteOnly	327,000,000.00	514.00	497.17
55-59	cigarettePlus	468,200,000.00	576.00	583.40
55-59	no	63,200,000.00	55.00	63.33
60-64	cigarPipeOnly	84,600,000.00	113.00	117.04
60-64	cigaretteOnly	379,100,000.00	778.00	758.66
60-64	cigarettePlus	605,200,000.00	1,001.00	992.58
60-64	no	106,700,000.00	117.00	140.73
65-69	cigarPipeOnly	94,900,000.00	173.00	185.19
65-69	cigaretteOnly	242,100,000.00	689.00	683.37
65-69	cigarettePlus	388,000,000.00	901.00	897.57
65-69	no	89,700,000.00	170.00	166.87
70-74	cigarPipeOnly	82,400,000.00	212.00	211.32
70-74	cigaretteOnly	119,500,000.00	432.00	443.30
70-74	cigarettePlus	203,300,000.00	613.00	618.07
70-74	no	66,800,000.00	179.00	163.31
75-79	cigarPipeOnly	66,700,000.00	243.00	227.95
75-79	cigaretteOnly	43,600,000.00	214.00	215.54
75-79	cigarettePlus	87,100,000.00	337.00	352.89
75-79	no	36,100,000.00	120.00	117.62
80+	cigarPipeOnly	53,700,000.00	253.00	244.86
80+	cigaretteOnly	11,300,000.00	63.00	74.53
80+	cigarettePlus	34,500,000.00	189.00	186.49
80+	no	27,400,000.00	120.00	119.11

```
check_overdispersion(mod1)
```

```
# Overdispersion test
```


```
dispersion ratio = 0.859
Pearson's Chi-Squared = 20.619
p-value = 0.661
```

Lecture. Le rapport de dispersion vaut $X^2/df = 0,86$, proche de 1 et même légèrement inférieur ($p = 0,661$) : **pas de sur-dispersion**. L'hypothèse $\text{Var}(Y) = \mathbb{E}[Y]$ est compatible avec les données, donc les erreurs standards et les tests du modèle de Poisson sont fiables. Il n'est pas nécessaire de passer à un modèle quasi-Poisson ou binomial négatif.

En cas de sur-dispersion marquée, envisagez **Quasi-Poisson** (`family = quasipoisson`) ou **Négative Binomiale** (`MASS::glm.nb`) et comparez l'ajustement.

Graphiques (facultatifs)

```
shapes_9 <- c(16, 17, 15, 3, 7, 8, 0, 1, 2) # à ta convenance
ggplot(df_preds, aes(mu_hat, y_obs, color = smoking_status, shape = age)) +
  geom_point(size = 2) +
  geom_abline(intercept = 0, slope = 1, linetype = 2) +
  scale_shape_manual(values = shapes_9) +
  labs(x = "Comptes attendus (mod1)", y = "Comptes observés",
       title = "Observé vs Attendu : GLM Poisson (mod1)")
```



Bilan

- Le modèle de Poisson avec offset permet d'estimer des **taux de décès** en fonction du tabagisme et de l'âge.
- Le modèle additif âge + tabac (mod1) **s'ajuste bien** (déviante 21,49 pour 24 df, $p = 0,610$), sans sur-dispersion.
- L'**âge** est le facteur dominant : le taux est multiplié par 17,2 entre 40-44 ans et 80 ans et plus.
- Le **tabac** a un effet significatif ($LR = 170,24$, 3 df), qui tient à la **cigarette** : à âge égal, les fumeurs de cigarettes seules ont un taux 1,52 fois plus élevé que les non-fumeurs, alors que cigare et pipe seuls ne s'en distinguent pas.
- La variable binaire « cigarette oui/non » est **trop grossière** (rejetée par le test LR contre mod1) : le type de produit compte.
- Les **IRR** offrent une interprétation intuitive : *par rapport à la catégorie de référence, combien de fois le taux de décès est-il multiplié*. Il faut toujours vérifier quelle est cette référence.

Conseil pratique : en recherche appliquée, vérifiez toujours la sur-dispersion et documentez les hypothèses de variance (Poisson vs quasi-Poisson vs binomiale négative).