

TD 2 : Régression logistique (R)

Années universitaires 2025–2026 et 2026–2027 ■ Parcours Économie de la santé
& Développement durable

Pierre Beaucoral

Ce TD reprend l'exemple et le dictionnaire de variables (`age`, `ed`, `employ`, `address`, `income`, `debtinc`, `credebt`, `othdebt`, `default`) décrits dans la ressource d'origine.

Données à récupérer: `bankloanT.xls` (ENT).

Packages utilisés : `tidyverse`, `readxl`, `janitor`, `broom`, `ResourceSelection`, `pROC`, `gt`, `ggplot2`.

Rappel de cours : Modèles Logit et Probit

Quand utiliser ces modèles ?

La **régression logistique** et la **régression probit** sont utilisées lorsque la variable à expliquer est **binaire** :

$$Y_i \in 0, 1$$

- Exemple : défaut de paiement / pas de défaut
- Objectif : estimer la **probabilité** $P(Y_i = 1 \mid X_i)$ en fonction de caractéristiques X_i

Les variables explicatives peuvent être **quantitatives ou qualitatives**.

Pourquoi ne pas utiliser une régression linéaire ?

Une régression linéaire classique :

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i$$

peut donner des valeurs **prédites hors de $[0, 1]$** , ce qui est absurde pour une probabilité.

Il faut donc introduire une **fonction de lien** qui transforme l'intervalle $(0, 1)$ en $\mathbb{R}$.

Fonction de lien du modèle Logit

$$\text{logit}(p) = \ln\left(\frac{p}{1-p}\right) \quad \text{et} \quad p = \frac{e^x}{1+e^x} = \frac{1}{1+e^{-x}}$$

Le modèle s'écrit :

$$\text{logit}(P(Y_i = 1)) = \beta_0 + \beta_1 X_{i1} + \dots + \beta_p X_{ip}$$

Les coefficients β_j s'interprètent via les **odds-ratios** : $OR_j = e^{\beta_j}$

Fonction de lien du modèle Probit

Le modèle Probit suppose qu'il existe une **variable latente** (Y_i^*) telle que :

$$Y_i^* = \beta_0 + \beta_1 X_{i1} + \dots + \beta_p X_{ip} + \varepsilon_i \quad \text{avec} \quad \varepsilon_i \sim \mathcal{N}(0, 1)$$

et on observe :

$$Y_i = 1 \text{ si } Y_i^* > 0$$

d'où :

$$P(Y_i = 1) = \Phi(\beta_0 + \beta_1 X_i) \text{ où } \Phi \text{ est la fonction de répartition de la loi normale centrée réduite.}$$

Comparaison graphique des liens Logit et Probit

```
library(ggplot2)

x <- seq(-6, 6, length.out = 200)

df_link <- data.frame( x = x, Logit = 1 / (1 + exp(-x)), Probit = pnorm(x) )

ggplot(df_link, aes(x = x)) + geom_line(aes(y = Logit, color = "Logit")) + geom_line(aes(y =
```




Figure 1: Comparaison des fonctions de lien Logit et Probit

Observation :

- Les deux courbes sont très proches ; la principale différence réside dans la forme légèrement plus aplatie du Probit aux extrémités.
- En pratique, les résultats logit et probit sont très similaires (seuls les coefficients changent d'échelle : $\beta_{\text{logit}} \approx 1.6\beta_{\text{probit}}$).

Interprétation économique

- **Logit** : privilégié quand on interprète les coefficients en termes d'odds-ratios (très courant en santé et sciences sociales).
- **Probit** : privilégié en économie microéconométrique, car il se relie naturellement à un modèle de variable latente et au Tobit.

```
x <- seq(0, 40, length.out = 200)
beta0 <- -2.5; beta1 <- 0.12
p_hat <- 1 / (1 + exp(-(beta0 + beta1 * x)))

df_ex <- data.frame(debt_income = x, p_hat = p_hat)

ggplot(df_ex, aes(debt_income, p_hat)) +
  geom_line(color = "seagreen4", linewidth = 1.2) +
  labs(
    title = "Effet du ratio dette/revenu sur la probabilité de défaut (modèle logit)",
    x = "Ratio dette / revenu (%)",
    y = "Probabilité prédite de défaut"
  ) +
  theme_minimal()
```




Figure 2: Exemple : probabilité prédite de défaut selon le ratio dette/revenu

Interprétation :

→ Lorsque le ratio dette/revenu augmente, la probabilité prédite de défaut croît de manière sigmoïde : faible au départ, elle augmente rapidement autour de la zone moyenne, puis se stabilise.

Résumé comparatif

Caractéristique	Logit	Probit
Fonction de lien	$\text{logit}(p) = \log(p/(1-p))$	$\Phi^{-1}(p)$
Distribution implicite des erreurs	Logistique	Normale centrée réduite
Interprétation des coefficients	Odds-ratios	Z-scores latents
Usages typiques	Santé, sociologie	Économie, finance
Résultats empiriques	Quasi identiques (_logit 1.6 _probit)	

À retenir : Logit et Probit sont deux manières voisines de modéliser une probabilité binaire. Le choix entre les deux est souvent une question de convention disciplinaire ou d'interprétabilité des coefficients.

Questions TD

Télécharger le fichier bankloanT.xls depuis l'ENT, puis importer les données dans R

```
df0 <- read_excel("./data/bankloanT.xls") |> clean_names()
df0 |> glimpse()
```

```
Rows: 850
Columns: 9
$ age      <dbl> 44, 26, 47, 31, 33, 45, 45, 35, 38, 32, 36, 47, 34, 39, 27, 4~
$ ed       <chr> "College degree", "High school degree", "Some college", "Did ~
$ employ   <dbl> 18, 6, 16, 5, 10, 21, 16, 17, 7, 0, 4, 23, 16, 8, 7, 8, 9, 0,~
$ address  <dbl> 23, 6, 7, 7, 2, 26, 21, 4, 4, 4, 17, 11, 9, 0, 8, 18, 6, 5, 1~
$ income   <dbl> 78, 30, 266, 23, 54, 132, 80, 42, 64, 20, 25, 115, 79, 21, 30~
$ debtinc  <chr> "1", "1", "2", "2", "3", "3", "3", "3", "3", "3", "4", "4", "~
$ creddebt <chr> "0.56472", "0.1437", "2.19184", "0.046", "0.11988", "2.55816"~
$ othdebt  <chr> "0.21528", "0.1563", "3.12816", "0.414", "1.50012", "1.40184"~
$ default  <chr> NA, "No", NA, NA, NA, "No", "No", "No", "No", "Yes", NA, "No"~
```

Etudier la distribution de la variable ed. Créer une variable catégorielle, puis une variable ne contenant que 4 classes.

```
df0 |> count(ed) |> arrange(desc(n))
```

```
# A tibble: 5 x 2
  ed                n
  <chr>            <int>
1 Did not complete high school 460
2 High school degree      235
3 Some college            101
```

4 College degree	49
5 Post-undergraduate degree	5


```
df1 <- df0 |>
  mutate(
    ed5 = factor(ed,
      levels = c(
        "Did not complete high school",
        "High school degree",
        "Some college",
        "College degree",
        "Post-undergraduate degree"
      ),
      ordered = TRUE),
    ed4 = fct_collapse(ed5,
      "College or above" = c("College degree", "Post-undergraduate degree")
    )
  )

df1 |> count(ed4)
```

```
# A tibble: 4 x 2
  ed4          n
<ord>      <int>
1 Did not complete high school 460
2 High school degree          235
3 Some college                101
4 College or above            54
```

```
ggplot(df1, aes(x = ed4)) +
  geom_bar(fill = "steelblue") +
  labs(x = "Niveau d'éducation (4 classes)", y = "Effectif",
    title = "Distribution de l'éducation dans l'échantillon") +
  theme_minimal()
```

Distribution de l'éducation dans l'échantillon



Etudier la matrice des corrélations entre les 7 variables quantitatives présentes.


```
num_vars <- c("age","employ","address","income","debtinc","creddebt","othdebt")
df1 <- df1 |>
  mutate(
    debtinc = as.numeric(debtinc),
    creddebt = as.numeric(creddebt),
    othdebt = as.numeric(othdebt)
  )
cor_mat <- df1 |>
  select(all_of(num_vars)) |>
  drop_na() |>
  cor()

library(ggcorrplot)
ggcorrplot(
  cor_mat,
  hc.order = TRUE,          # ordonne les variables par similarité
  lab = TRUE,               # affiche les coefficients
  lab_size = 3,
  colors = c("tomato2", "white", "seagreen3"),
  title = "Corrélogramme des variables quantitatives",

```

```
ggtheme = theme_minimal()
)
```

Corrélogramme des variables quantitatives



Recoder la variable à expliquer (default) en variable quantitative puis réaliser une première régression logistique incluant toutes les variables explicatives quantitatives.

```
df2 <- df1 |>
  mutate(
    default_num = case_when(
      default == "Yes" ~ 1,
      default == "No" ~ 0,
      TRUE ~ NA_real_ # conserve les NA existants
    )
  )
form1 <- default_num ~ age + employ + address + income + debtinc + creddebt + othdebt
mod1 <- glm(form1, data=df2, family=binomial("logit"))
summary(mod1)
```

Call:

```
glm(formula = form1, family = binomial("logit"), data = df2)
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)	
(Intercept)	-1.377693	0.571585	-2.410	0.0159	*
age	0.033694	0.017341	1.943	0.0520	.
employ	-0.265035	0.031996	-8.283	< 2e-16	***
address	-0.103964	0.023193	-4.483	7.37e-06	***
income	-0.007530	0.008099	-0.930	0.3525	
debtinc	0.065253	0.030620	2.131	0.0331	*
creddebt	0.628263	0.113738	5.524	3.32e-08	***
othdebt	0.070289	0.077693	0.905	0.3656	

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 804.36 on 699 degrees of freedom
Residual deviance: 552.21 on 692 degrees of freedom
(150 observations effacées parce que manquantes)
AIC: 568.21

Number of Fisher Scoring iterations: 6

Réaliser une deuxième régression logistique incluant aussi la variable educ en classe. Enregistrer aussi les résultats de ce modèle, qui est le modèle le plus complexe que nous appliquerons à ces données.

```
form2 <- update(form1, . ~ . + ed4)
mod2 <- glm(form2, data=df2, family=binomial("logit"))
summary(mod2)
```

Call:

```
glm(formula = form2, family = binomial("logit"), data = df2)
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)	
(Intercept)	-1.469161	0.585721	-2.508	0.0121	*
age	0.036527	0.017564	2.080	0.0376	*

employ	-0.259784	0.033353	-7.789	6.76e-15	***
address	-0.105959	0.023331	-4.542	5.58e-06	***
income	-0.007386	0.007927	-0.932	0.3515	
debtinc	0.071049	0.030620	2.320	0.0203	*
creddebt	0.616294	0.112296	5.488	4.06e-08	***
othdebt	0.052860	0.078374	0.674	0.5000	
ed4.L	0.003376	0.321415	0.011	0.9916	
ed4.Q	-0.334133	0.276144	-1.210	0.2263	
ed4.C	-0.030154	0.249875	-0.121	0.9039	

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 804.36 on 699 degrees of freedom
 Residual deviance: 550.03 on 689 degrees of freedom
 (150 observations effacées parce que manquantes)
 AIC: 572.03

Number of Fisher Scoring iterations: 6

Tester l'ajustement de ce modèle complet, grâce à la commande `hoslem.test`, où `g` est le nombre de groupes de niveaux différents de fonction prédictive utilisé pour le test. Varier les valeurs de `g` pour vérifier la robustesse du résultat.

```
hoslem.test(mod2$y, fitted(mod2), g=4)
```

Hosmer and Lemeshow goodness of fit (GOF) test

data: mod2\$y, fitted(mod2)
 X-squared = 2.3796, df = 2, p-value = 0.3043

```
hoslem.test(mod2$y, fitted(mod2), g=5)
```

Hosmer and Lemeshow goodness of fit (GOF) test

data: mod2\$y, fitted(mod2)
 X-squared = 0.9883, df = 3, p-value = 0.8041

```
hoslem.test(mod2$y, fitted(mod2), g=6)
```

Hosmer and Lemeshow goodness of fit (GOF) test

```
data: mod2$y, fitted(mod2)
X-squared = 5.3862, df = 4, p-value = 0.2499
```

```
hoslem.test(mod2$y, fitted(mod2), g=7)
```

Hosmer and Lemeshow goodness of fit (GOF) test

```
data: mod2$y, fitted(mod2)
X-squared = 2.0796, df = 5, p-value = 0.838
```

```
hoslem.test(mod2$y, fitted(mod2), g=8)
```

Hosmer and Lemeshow goodness of fit (GOF) test

```
data: mod2$y, fitted(mod2)
X-squared = 3.9178, df = 6, p-value = 0.6878
```

```
hoslem.test(mod2$y, fitted(mod2), g=9)
```

Hosmer and Lemeshow goodness of fit (GOF) test

```
data: mod2$y, fitted(mod2)
X-squared = 5.5538, df = 7, p-value = 0.5927
```

```
hoslem.test(mod2$y, fitted(mod2), g=10)
```

Hosmer and Lemeshow goodness of fit (GOF) test

```
data: mod2$y, fitted(mod2)
X-squared = 5.9712, df = 8, p-value = 0.6505
```

Grâce à la commande `anova`, réaliser un test de rapport de vraisemblance entre les deux modèles ajustés, et conclure sur la significativité de la variable `educ`.

```
anova(mod1, mod2, test="Chisq")
```

Analysis of Deviance Table

Model 1: `default_num ~ age + employ + address + income + debtinc + creddebt + othdebt`

Model 2: `default_num ~ age + employ + address + income + debtinc + creddebt + othdebt + ed4`

	Resid. Df	Resid. Dev	Df	Deviance	Pr(>Chi)
1	692	552.21			
2	689	550.03	3	2.176	0.5367

- La p-value = **0.54** → on ne rejette pas H_0 .
- Autrement dit :

l'ajout de la variable d'éducation `ed4` n'améliore pas significativement la qualité du modèle.

Ôter la variable la moins significative du modèle retenu. Vérifier que la P-value du test

de rapport de vraisemblance entre les modèles avec et sans cette variable est égale ou très proche de la P-value du test bilatéral de nullité du coefficient associé à la variable.

```
form3 <- update(form1, . ~ . - othdebt)
mod3 <- glm(form3, data=df2, family=binomial("logit"))
summary(mod3)
```

Call:

```
glm(formula = form3, family = binomial("logit"), data = df2)
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-1.591125	0.522271	-3.047	0.00231 **
age	0.033618	0.017383	1.934	0.05312 .

```

employ      -0.257986    0.030791   -8.379   < 2e-16 ***
address     -0.103119    0.023141   -4.456   8.34e-06 ***
income      -0.002526    0.006320   -0.400   0.68939
debtinc      0.086173    0.020071    4.293   1.76e-05 ***
creddebt     0.595490    0.104930    5.675   1.39e-08 ***
---

```

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

```

Null deviance: 804.36  on 699  degrees of freedom
Residual deviance: 553.02  on 693  degrees of freedom
(150 observations effacées parce que manquantes)
AIC: 567.02

```

Number of Fisher Scoring iterations: 6

```
anova(mod2, mod3, test="Chisq")
```

Analysis of Deviance Table

```

Model 1: default_num ~ age + employ + address + income + debtinc + creddebt +
      othdebt + ed4
Model 2: default_num ~ age + employ + address + income + debtinc + creddebt
      Resid. Df Resid. Dev Df Deviance Pr(>Chi)
1          689      550.03
2          693      553.02 -4   -2.9856   0.5602

```

Une variable est à nouveau très peu significative. Ajuster un nouveau modèle sans cette variable. Sauvegarder les valeurs prédites par ce modèle.

```

form4 <- update(form3, . ~ . - income)
mod4 <- glm(form4, data=df2, family=binomial("logit"))
summary(mod4)

```

Call:

```
glm(formula = form4, family = binomial("logit"), data = df2)
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)	
(Intercept)	-1.63128	0.51268	-3.182	0.00146	**
age	0.03256	0.01717	1.896	0.05799	.
employ	-0.26076	0.03011	-8.662	< 2e-16	***
address	-0.10365	0.02309	-4.490	7.13e-06	***
debtinc	0.08926	0.01855	4.813	1.49e-06	***
creddebt	0.57265	0.08723	6.565	5.20e-11	***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 804.36 on 699 degrees of freedom
Residual deviance: 553.18 on 694 degrees of freedom
(150 observations effacées parce que manquantes)
AIC: 565.18

Number of Fisher Scoring iterations: 6

```
anova(mod3, mod4, test="Chisq")
```

Analysis of Deviance Table

Model 1: default_num ~ age + employ + address + income + debtinc + creddebt

Model 2: default_num ~ age + employ + address + debtinc + creddebt

	Resid. Df	Resid. Dev	Df	Deviance	Pr(>Chi)
1	693	553.02			
2	694	553.18	-1	-0.15877	0.6903

Etablir le tableau de contingence des individus bien ou mal classés avec une règle de coupure à 0,5

```
# Probabilités prédites
df2_nona <- df2 |> drop_na(age, employ, address, income, debtinc, creddebt, othdebt, default)

p_hat <- predict(mod4, newdata = df2_nona, type = "response")

df2_nona <- df2_nona |>
  mutate(
```

```

    p_hat = p_hat,
    pred_class = if_else(p_hat >= 0.5, 1, 0)
  )

table(Predicted = df2_nona$pred_class, Observed = df2_nona$default_num)

```

```

      Observed
Predicted  0   1
      0 476  89
      1  41  94

```

```

mean(df2_nona$pred_class == df2_nona$default_num, na.rm = TRUE)

```

```

[1] 0.8142857

```


Etablir la courbe ROC pour le « meilleur » modèle, puis calculer les “probabilités prédites” et étudier leur distribution

```

roc_obj <- roc(df2_nona$default_num, df2_nona$p_hat)

plot(roc_obj, main="Courbe ROC : Modèle logit 2025")


```



```
auc(roc_obj)
```

Area under the curve: 0.8582

```
ggplot(df2_nona, aes(x = p_hat, fill = factor(default_num))) +  
  geom_histogram(alpha = 0.6, position = "identity", bins = 30) +  
  labs(title = "Distribution des probabilités prédites par classe réelle",  
        x = "p̂(default = 1)", fill = "Défaut observé") +  
  theme_minimal()
```



Interprétation du graphe

- L'axe des abscisses montre les **probabilités prédites de défaut** $\hat{p} = P(\text{default} = 1|X)$.
- L'axe des ordonnées montre le **nombre d'individus** dans chaque intervalle de probabilité.
- La couleur rouge (0) représente les **emprunteurs qui n'ont pas fait défaut**.
- La couleur bleue (1) représente les **emprunteurs qui ont fait défaut**.

Refaire la même modélisation avec un modèle Probit et observer les différences et ressemblances avec la modélisation Logit.

```
mod_probit <- glm(formula(mod4), data=df2, family=binomial("probit"))
summary(mod_probit)
```

Call:

```
glm(formula = formula(mod4), family = binomial("probit"), data = df2)
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)	
(Intercept)	-0.963869	0.297087	-3.244	0.00118	**
age	0.018237	0.009972	1.829	0.06742	.
employ	-0.144955	0.016217	-8.939	< 2e-16	***
address	-0.055609	0.012835	-4.333	1.47e-05	***
debtinc	0.051049	0.010563	4.833	1.35e-06	***
creddebt	0.322172	0.048056	6.704	2.03e-11	***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 804.36 on 699 degrees of freedom
Residual deviance: 554.57 on 694 degrees of freedom
(150 observations effacées parce que manquantes)
AIC: 566.57

Number of Fisher Scoring iterations: 6

Pour aller plus loin...

Supposant qu'un individu ne remboursant pas son emprunt coûte en moyenne 100000\$, et qu'un individu payant son emprunt rapporte en moyenne 40000\$, on peut calculer (...) qu'il est optimal de n'accorder un prêt qu'aux individus ayant une probabilité de rembourser estimée à 0,7 ou plus.

Règle de décision (probabilité de remboursement ≥ 0.7)

```
df2_nona <- df2_nona |> mutate(p_repay = 1 - p_hat, grant = as.numeric(p_repay >= 0.7))
mean(df2_nona$grant, na.rm = TRUE)
```

```
[1] 0.64
```

Etablir le tableau de contingence des individus bien ou mal classés en considérant comme défaillants potentiels tous les individus ayant moins de 70% de chances de rembourser. Commenter ce tableau.

```
thr_default <- 0.3
table(Predicted = df2_nona$p_hat >= thr_default, Observed = df2_nona$default_num)
```

	Observed	
Predicted	0	1
FALSE	405	43
TRUE	112	140

```
tab <- table(Predicted = df2_nona$p_hat >= thr_default,
             Observed = df2_nona$default_num)
accuracy <- sum(diag(tab)) / sum(tab)
accuracy
```

```
[1] 0.7785714
```

```
prop.table(tab, 2) # pourcentage par classe observée
```

	Observed	
Predicted	0	1
FALSE	0.7833656	0.2349727
TRUE	0.2166344	0.7650273

En fixant le seuil à 0,3 (c'est-à-dire en considérant comme « défaillant potentiel » tout individu ayant moins de 70 % de chances de rembourser), le modèle devient **plus prudent** : il classe davantage d'individus comme risqués. Le nombre de vrais

positifs (défaillants correctement détectés) augmente, mais au prix d'une hausse des faux positifs (bons payeurs injustement rejetés).

Autrement dit, la règle minimise les pertes dues aux impayés, mais réduit le volume de prêts accordés. C'est un **compromis classique entre risque de crédit et rentabilité** :

Plus le seuil est bas, plus la banque protège son portefeuille, mais plus elle refuse de bons clients.